PRUEBA TÉCNICA PARA ANALISTA DE CIENCIA DE DATOS

Nombre del aspirante: Daniel Sarmiento Vanegas

Cédula: 1107520134

Correo: dsarmientovs@gmail.com

Teléfono: 3113845465

DISCLAIMER IMPORTANTE

Esta es una prueba técnica con fines exclusivamente evaluativos. Los datos presentados son completamente ficticios y generados únicamente para propósitos de evaluación. Los resultados y análisis producidos durante esta prueba NO serán utilizados por la empresa para fines comerciales reales. Esta evaluación no conlleva compensación económica y su único objetivo es medir las competencias técnicas del aspirante.

Duración: 24 horas

---

1. Construye un RPA que ingrese a la página de la DIAN, consulte los siguientes códigos únicos de facturación CUFE y descargue los PDF de la representación gráfica de cada factura. Ten presente que la página tiene Captcha y tu proceso automatizado lo debe resolver.

   https://catalogo-vpfe.dian.gov.co/User/SearchDocument

   CUFES:

   1. eccc372e4bdb8125cf2e896b405ddb91918c7c6d92238892e3b36bd3b6a86929a3c47ed18ae8f559a1bf51b89ab560f1

   2. 8e7b821b46445807245ad6c223d6a054923cea3e5dc59983e55a40cfeac2a4f570eccb198446b27d15c8d834c2e2ced9

   3. 6a7ec741dd95ff7f5240481b3ed287f85eea3b665a8b26b91b376095f9bb134d2397ec96586fd16e116ef247a6506770

   4. c2e740942c1925d57f2e82254f21992cbad461a0df57fd42a1475fbe71ba5ab68a824c03487cbc19e80c50e436dd30fe

5.
3e6331e537f08a54ec2d9f38904afaae80b16ffa502a12fd9aba388048d50d76b311809be9236aaa1bd1cc781a9d87f3

6.

f639eb72baf2e301eddde8e8e5087295831a12c781d4cf6b4671932cdfa3599223aa3375af807a1f5d66aa1543c9fb91

7.

2a90ab2ce6b54e505fc9f463bffb528244abef80d9ab1a9a39d771169c7cfe52b9a48b6feab1fdceb8b4b59ff6e319db

8.

341a447c4891f8e302771bf6a6d95d7011e72d44a8cb670356cbb5e92549824eb0071c542261d837978cfd351d2131d1

9.

bbed883f80308e0e0e16e52a1286d71274b1a78419875458c590fcec41c065eda762aaef478775dc219de3c5e2d6400b

10.

70d1aab6f793d4fc7151d69400138cf1bd147e54aaeaf274072898f9d12d979e86e8de79fef27668896db76589323ad0

2. Crea un procedimiento para extraer el texto de las imágenes que acabas de exportar. Debes crear un data frame para cada archivo y exportar los datos en un archivo csv. Las variables que debes extraer son:

- De las secciones “Datos del Documento” y “Datos del Emisor/Vendedor”:

  Número de factura, Fecha de emisión, NIT del emisor.

- De la tabla en “Detalles del Producto”:

  Código, Descripción, Cantidad, Precio unitario.

Reporta los tiempos empleados, restricciones métricas del proceso.

RESUMEN

Tiempos

fase 1 (descarga): 134.92 s (98.0%)

fase 2 (PDFs y CSV): 2.80 s (2.0%)

total: 137.72 s

Fase 1

10 CUFEs: 10 descargados, 0 ya estaban, 0 fallaron

tiempo por CUFE: promedio 11.42 s, mín 3.82 s, máx 61.67 s, desv. 18.02 s

a la primera (sin reintentos): 9 de 10 (90.0%)

intentos en total: 11 (1.10 por CUFE)

esperando a 2captcha: 34.07 s (25.2% de la fase 1)

pausas entre CUFEs: 17.92 s (13.3% de la fase 1)

Fase 2

10 PDFs leídos, 21 líneas de producto

tiempo por PDF: promedio 0.279 s, mín 0.248 s, máx 0.351 s

velocidad: 3.57 PDFs por segundo

PDFs sin ningún ítem: 0

Configuración usada

timeout de descarga: 30 s por intento

timeout del diálogo del NIT: 10 s

timeout del resultado de la búsqueda: 30 s

2captcha: 8 hilos, precarga de 4 docs, el token dura 240 s

pausa entre docs: entre 1.5 y 3.0 s (aleatoria)

reintentos: máximo 3 por CUFE

Entrega

Envía este documento con las respuestas, tu código en python y un enlace a un repositorio de GitHub con un README claro .